## Projet : Analyse des ventes en temps réel - Data Streaming

**Contexte**

Une entreprise de commerce en ligne souhaite disposer d'une vision actualisée de son activité commerciale afin de faciliter la prise de décision.

Dans ce contexte, l'entreprise dispose d'un historique de ventes contenant plusieurs centaines de milliers de transactions réalisées sur sa plateforme. Cet historique sera utilisé pour **simuler un flux continu** de nouvelles transactions, transmises progressivement au système de traitement.

On vous demande de développer une solution ergonomique permettant d'aider le responsable de l'entreprise pour le suivi de son activité commerciale et la prise de décision. Utilisez Apache Spark Structured Streaming. Le système devra traiter les transactions au fur et à mesure de leur arrivée. Exemple de fonctionnalités: suivre les ventes, identifier rapidement les produits les plus vendus et autres indicateurs pertinents.

**Dataset:** Le projet s'appuiera sur le dataset **Online Retail Dataset.** Disponible ici: https://archive.ics.uci.edu/dataset/352/online+retail [1]

Ce dataset contient environ 540 000 transactions réalisées par un site de vente en ligne.

Extrait du fichier :

**InvoiceNo,StockCode,Description,Quantity,InvoiceDate,UnitPrice,CustomerID,Country**
536365,85123A,WHITE HANGING HEART T-LIGHT HOLDER,6,2010-12-01 08:26,2.55,17850,United Kingdom
536365,71053,WHITE METAL LANTERN,6,2010-12-01 08:26,3.39,17850,United Kingdom

Présentez et expliquez les principaux résultats obtenus.

[1] Chen, D. (2015). Online Retail [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5BW33.

Ajoutez une extension au projet. L'utilisation d'Apache Kafka ( et/ou d'Apache Flink) avec les données du projet est encouragée (valorisée dans la partie améliorations) pour enrichir le projet.

Vous êtes  libre d'enrichir le dataset, ou de diminuer le nombre de lignes si besoin. Vous êtes encouragés à proposer des améliorations.

**Présentation finale:**

- Lors de la dernière séance, chaque groupe devra présenter son travail ( Diapos + démonstration en direct (live demo), Durée: 10 minutes ). La présentation sera suivie d'une discussion et de questions sur le contenu du module.
- Un rapport en PDF représentant votre travail est à déposer sur la plateforme.